

第 1 次实验报告

2022111663 刘博飞

2024 年 9 月 19 日

1 任务 1

对提供的两组数据 `logistic_data1.csv` , `logisitic_data2.csv` 通过逻辑回归进行分类，找出决策面。

1.1 数据 1

通过线性回归得到的运行结果如下图所示:




图 1: 数据 1 运行结果

1.2 数据 2


数据 2 需使用 x_0, x_1 两个特征构造高维特征，并分别尝试无正则化和加入 L2 正则项来查找决策面，对比有无正则项时的分类难度和结果。

对于高维特征的选取，我采取了高次多项式的形式，表达式如下：


$$h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \dots + \theta_n x^n + \dots \quad (1)$$

实验中，分别选择了 $n = 3, 4, 5, 6$ 四种情况，对每种情况分别进行无正则化和 L2 正则化，并记录了分类决策面和分类时间（衡量分类难度）。


分类决策面如下图所示：




(a) $n = 3, L2 = \text{False}$




(b) $n = 3, L2 = \text{True}$




(c) $n = 4, L2 = \text{False}$




(d) $n = 4, L2 = \text{True}$




(e) $n = 5, L2 = \text{False}$



(f) $n = 5, L2 = \text{True}$



(g) $n = 6$, $L2 = \text{False}$



(h) $n = 6$, $L2 = \text{True}$

分类时间如下表所示：

表 1: 数据 2 分类运行时间

n	无正则化	L2 正则化
3	0.9981s	1.9410s
4	1.0721s	1.9867s
5	1.0111s	1.9468s
6	1.0978s	1.9374s

通过分析实验数据，我们发现，加入正则化后模型的运行时间增加了，这说明 L2 正则化会引入更多的计算量从而使分类更困难。同时，对比加入 L2 正则化后的图像，发现边界略微大于未加入正则化的图像，围住了更多的蓝色点，这是因为 L2 正则化通过加入一个参数平方和的惩罚项，限制了过大的参数，增加了模型的泛化能力，从而防止了过拟合。

2 任务 2

对提供的鸢尾花数据集通过逻辑回归进行分类。在训练集 `iris_train.csv` 上训练决策面，并在测试集 `iris_test.csv` 上执行分类任务，得到准确率如下表。

表 2: 三分类准确率

闭环准确率	开环准确率
98.0952%	95.5556%

A 任务 1.1 核心代码

```
1  def sigmoid(z):
2      return 1 / (1 + np.exp(-z))
3
4  def compute_cost(X, y, theta):
5      h = sigmoid(X @ theta) # 计算预测值
6      cost = (y.T @ np.log(h) + (1 - y).T @ np.log(1 - h)) / m
7      # 对数损失函数
8      return cost
9
10 def gradient_descent(X, y, theta, alpha, num_iters):
11     cost_history = []
12
13     for _ in range(num_iters):
14         h = sigmoid(X @ theta)
15         gradient = X.T @ (h - y) / m
16         theta -= alpha * gradient
17         cost_history.append(compute_cost(X, y, theta))
18     return theta, cost_history
```

B 任务 1.2 核心代码

```
1  def polynomial_features(x0, x1, degree):
2      # 计算 x0 和 x1 的不同幂次
3      features = [np.ones_like(x0)] # 添加偏置项列
4      for d in range(1, degree + 1):
5          features.append(x0 ** d)
6          features.append(x1 ** d)
7      # 通过按列拼接生成最终的特征矩阵
8      return np.column_stack(features)
9
10 def sigmoid(z):
11     return 1 / (1 + np.exp(-z))
12
13 # 定义损失函数和梯度计算
14 def compute_cost(X, y, theta):
15     h = sigmoid(X @ theta) # 计算预测值
16     # todo: 决定是否正则化
17
18     # cost = (y.T @ np.log(h) + (1 - y).T @ np.log(1 - h)) / m
19     # 对数损失函数
20
21     cost = (y.T @ np.log(h) + (1 - y).T @ np.log(1 - h)) / m
22
23     + (Lambda / (2 * m)) * np.sum(theta[1:] ** 2)
24
25     return cost
26
27 def gradient_descent(X, y, theta, alpha, num_iters):
28     cost_history = []
29
30     for _ in range(num_iters):
31         h = sigmoid(X @ theta)
32
33         if L2:
34             gradient = np.zeros_like(theta)
35             gradient[0] = 1 / m * (X[:, 0].T @ (h - y))
36             # 偏置项的梯度, 不进行正则化
37             gradient[1:] = 1 / m * (X[:, 1:].T @ (h - y)) + (Lambda /
38                 ↪ m) * theta[1:]
39             # 其他参数的梯度, 加入正则化项
```

```

39         else:
40             gradient = X.T @ (h - y) / m
41             theta -= alpha * gradient
42             # cost_history.append(compute_cost(X, y, theta))
43     return theta, cost_history
44
45 # 绘制决策边界的函数
46 def plot_decision_boundary(x0, x1, theta, degree):
47     # 创建一个二维网格
48     u = np.linspace(min(x0) - 1, max(x0) + 1, 100)
49     v = np.linspace(min(x1) - 1, max(x1) + 1, 100)
50     U, V = np.meshgrid(u, v) # [[100]*100]
51     # 使用多项式特征构造新的特征矩阵
52     UV_poly = polynomial_features(U.ravel(), V.ravel(), degree)
53     Z = UV_poly @ theta # 10000*1
54     Z = Z.reshape(U.shape)
55     # 绘制决策边界
56     plt.contour(U, V, Z, levels=[0], linewidths=2, colors='g')

```

C 任务2 核心代码

```
1  def softmax(z):
2      e_z = np.exp(z - np.max(z, axis=1, keepdims=True))
3      return e_z / np.sum(e_z, axis=1, keepdims=True)
4
5  def compute_cost(Y, Y_hat):
6      m = Y.shape[0]
7      cost = -np.sum(Y * np.log(Y_hat + 1e-9))/m
8      cost_history.append(cost)
9
10 def one_hot_encoding(y):
11     m = y.shape[0]
12     Y = np.zeros((m, 3))
13     for i in range(m):
14         Y[i, int(y[i])] = 1
15     return Y
16
17 def train(X, y, alpha, iteration):
18     features = 4
19     species = 3
20     Y = one_hot_encoding(y)
21     W = np.random.randn(features, species) * 0.01
22     b = np.zeros((1, species))
23     m = X.shape[0]
24     for i in range(iteration):
25         Z = X@W + b
26         Y_hat = softmax(Z)
27         compute_cost(Y, Y_hat)
28         dZ = Y_hat - Y
29         dW = X.T@dZ / m
30         db = np.sum(dZ, axis=0, keepdims=True) / m
31         W -= alpha * dW
32         b -= alpha * db
33     return W, b
34
35 def test(X, y, W, b):
36     Z = X@W + b
37     Y_hat = softmax(Z)
38     y_pred = np.argmax(Y_hat, axis=1)
39     sum = len(y_pred)
```

```
40     correct = 0
41     for i in range(sum):
42         if y_pred[i] == int(y[i]):
43             correct += 1
44     accuracy = correct/sum*100
45     return accuracy
```